

Fidélité Spatiale de Grad-CAM en Imagerie Thoracique

Évaluation quantitative contre des annotations radiologiques sur VinDr-CXR

Jonathan Suru

September 26, 2026

Abstract

Les méthodes d'explicabilité par carte de saillance, dont Grad-CAM, sont massivement utilisées en imagerie médicale pour interpréter les décisions des réseaux de neurones, mais leur fidélité spatiale est rarement validée quantitativement contre une vérité terrain clinique. Nous évaluons ici la capacité de trois variantes de CAM (Grad-CAM, Grad-CAM++, XGradCAM), appliquées à deux profondeurs d'un ResNet-50 entraîné en JAX/Flax sur 12 000 radiographies thoraciques VinDr-CXR, à localiser 14 pathologies annotées par bounding boxes de radiologues. Le classifieur multi-label atteint une aire sous la courbe (AUC) macro de 0.920, démontrant une discrimination élevée. En revanche, la localisation est fortement dépendante de la pathologie : le pointing game atteint 0.47 pour la cardiomegaly (lésion étendue centrale) mais chute à 0.00–0.09 pour les nodules, pneumothorax et épaississements pleuraux (lésions focales). Les tests de randomisation des poids confirment que la localisation de la cardiomegaly reflète des features apprises ($p = 2.86e-21$), tandis que, pour Grad-CAM, la localisation de l'ILD (pneumopathie interstitielle diffuse) est un artefact architectural ($p = 0.96$, non significatif) ; ce constat reste à étendre à Grad-CAM++, configuration non contrôlée ici. Nous recommandons layer4 + Grad-CAM++ comme configuration par défaut, la meilleure des six configurations évaluées sans qu'aucune ne soit satisfaisante pour les lésions focales, et documentons les limites cliniques de ces cartes pour les micro-lésions.

1 Introduction

L'interprétation des modèles de deep learning en imagerie médicale est un enjeu critique pour l'adoption clinique. Les cartes d'activation de classe (Class Activation Mapping, CAM), et en particulier Grad-CAM [1], sont devenues l'outil de facto pour visualiser les régions d'une radiographie influençant une prédiction. Pourtant, ces méthodes sont fréquemment déployées sans preuve quantitative que les régions mises en évidence correspondent aux structures anatomiques ou pathologiques jugées diagnostiques par les cliniciens. Un benchmark récent a d'ailleurs montré que les sept méthodes de saillance étudiées, Grad-CAM compris, restent significativement en deçà d'un expert humain pour la localisation des pathologies thoraciques [2].

Le dataset VinDr-CXR [3] offre une opportunité rare de répondre à cette question. Il fournit, en plus des labels de classification, des bounding boxes annotées par des radiologues expérimentés pour chaque pathologie détectée. Ces annotations constituent une vérité terrain spatiale indépendante, jamais utilisée à l'entraînement, permettant une évaluation objective de la fidélité spatiale des cartes de saillance.

Les contributions de ce travail sont les suivantes. Nous entraînons un classifieur multi-label ResNet-50 en JAX/Flax sur VinDr-CXR et rapportons ses performances de discrimination par AUC par classe. Nous évaluons systématiquement trois variantes de CAM (Grad-CAM, Grad-CAM++, XGradCAM) à deux profondeurs (layer3, layer4) à l'aide de quatre métriques de localisation complémentaires, en utilisant des tests statistiques appariés (mêmes images et pathologies) et une correction de fausse découverte (FDR, méthode de Benjamini–Hochberg). Nous validons la robustesse des résultats par trois contrôles : modèle non entraîné, randomisation des poids, et cartes aléatoires. Enfin, nous analysons la classe *No finding* par des métriques de diffusivité et décomposons tous les résultats par pathologie, avec effectifs et intervalles de confiance.

Résultats principaux

- AUC macro de **0.920** : le classifieur discrimine correctement les 15 classes.
- Pointing game maximal de **0.474** pour la cardiomegaly (layer4 + Grad-CAM++), mais **0.000–0.087** pour les lésions focales (nodule, pneumothorax, calcification).
- La localisation de la cardiomegaly survit à la randomisation des poids ($p = 2.86e-21$), celle de l'ILD non ($p = 0.96$), suggérant un artefact architectural pour cette dernière.

2 Méthodes

2.1 Dataset et prétraitement

Nous utilisons le dataset VinDr-CXR [3] (compétition VinBigData, Kaggle), comprenant 15 000 radiographies thoraciques postéro-antérieures au format DICOM. Chaque image est annotée par un panel de radiologues pour 14 pathologies, avec bounding boxes, plus une classe *No finding*. Les annotations sont multi-label : une même image peut présenter plusieurs pathologies simultanées.

Le split est déterministe (seed=42) en trois ensembles disjoints : 12 000 images d'entraînement (80%), 1 500 de validation (10%) et 1 500 de test (10%), ce dernier n'étant jamais utilisé pour l'entraînement ni la sélection de modèle. Les DICOM sont prétraités une seule fois et mis en cache au format .npy : pente/intercept de rescale, fenêtrage (ou percentiles 1–99), inversion MONOCHROME1 si nécessaire, redimensionnement à 224×224 . À l'entraînement, une normalisation ImageNet et un flip horizontal aléatoire sont appliqués.

2.2 Modèle

Le classifieur est un ResNet-50 [4] en JAX/Flax NNX, entraîné from scratch (pas de pré-entraînement ImageNet). L'architecture retourne explicitement les activations de layer3 ($14 \times 14 \times 256$) et layer4 ($7 \times 7 \times 512$) en plus des logits, permettant le calcul direct des cartes CAM sans hooks. La tête est une couche dense de 15 sorties avec sigmoïde indépendante par classe (multi-label), optimisée par entropie croisée binaire moyennée. L'optimiseur est AdamW [5] ($\text{lr}=10^{-3}$, $\text{weight decay}=10^{-4}$), batch size 64, 30 epochs; le checkpoint retenu correspond à la meilleure loss de validation.

2.3 Méthodes CAM

Trois variantes sont évaluées. **Grad-CAM** [1] pondère les activations par la moyenne spatiale des gradients du score de classe. **Grad-CAM++** [6] introduit une pondération d'ordre supérieur (α) corrigeant le biais en présence de multiples occurrences de la même classe. **XGradCAM** normalise par la somme des activations. Chaque carte est passée par ReLU, normalisée dans $[0, 1]$, puis upsamplée par interpolation bilinéaire à la résolution d'entrée (224×224).

2.4 Métriques de localisation

Pour chaque classe positive d'une image de test, la carte CAM est comparée à la bounding box correspondante (normalisée par les dimensions DICOM d'origine). Quatre métriques sont calculées : le **pointing game** (1 si l'argmax de la carte tombe dans la box), l'**energy in box** (fraction de l'activation totale contenue dans la box), l'**IoU** (intersection sur union entre la carte binarisée à 0.5 et la box), et la **distance normalisée** du maximum au centre de la box, rapportée à sa diagonale. Lorsque plusieurs radiologues annotent la même classe, le meilleur score est retenu : la carte est alors considérée comme correcte si elle coïncide avec au moins une des régions annotées, convention qui biaise les scores vers le haut et constitue une limite. Comme les cartes CAM ne sont pas des segmentations calibrées, l'IoU binarisée à un seuil de 0.5 reste une métrique imparfaite ; les métriques continues (energy in box, distance) font foi pour les comparaisons fines. Pour la classe *No finding*, sans bounding box, nous mesurons la **diffusivité** par entropie spatiale et concentration dans le top 1% des pixels.

2.5 Contrôles statistiques

Trois contrôles valident que les métriques mesurent le comportement appris et non un artefact : (i) un modèle **non entraîné** (initialisation aléatoire), (ii) un modèle dont les poids appris sont **randomisés** par permutation (détruit les features mais préserve la distribution), et (iii) des **cartes CAM aléatoires** uniformes. Les comparaisons de contrôles utilisent le test de Mann-Whitney U unilatéral (réel > nul), rapportées globalement et par pathologie. Les comparaisons entre couches et entre méthodes, elles, utilisent des tests de **Wilcoxon appariés** (chaque finding est comparé à lui-même), avec correction de **Benjamini-Hochberg** (FDR) par famille de tests. Les intervalles de confiance à 95 % sont obtenus par bootstrap à 2 000 répliques en réchantillonnant les images (et non les findings), afin de préserver la corrélation entre pathologies d'une même image.

3 Résultats

3.1 Performances de classification

Le modèle atteint un AUC macro de 0.920 (moyenne des 15 classes ; 0.916 sur les seules 14 pathologies) sur le test set. Les meilleures discriminations concernent *No finding* (0.978), Aortic enlargement (0.972) et Cardiomegaly (0.966). Les plus faibles restent correctes : Infiltration (0.873), Calcification (0.878) et Nodule/Mass (0.880). La table 1 donne l'AUC de chaque classe. Ce niveau de performance valide que le réseau a appris des représentations discriminantes pour les 14 pathologies, condition nécessaire pour que l'analyse de localisation soit interprétable. La figure 1 montre les courbes d'entraînement : la loss d'entraînement décroît régulièrement sur les 30 epochs, tandis que la loss de validation se stabilise autour de 0.15 après une dizaine d'epochs et reste bruitée sans divergence marquée; le checkpoint retenu correspond au minimum de la loss de validation.

Table 1: AUC par classe sur le test set. Macro sur les 15 classes : 0.920 (0.916 sur les 14 pathologies).

Classe	AUC	Classe	AUC	Classe	AUC
Aortic enlargement	0.972	ILD	0.886	Pleural effusion	0.943
Atelectasis	0.948	Infiltration	0.873	Pleural thickening	0.931
Calcification	0.878	Lung Opacity	0.915	Pneumothorax	0.894
Cardiomegaly	0.966	Nodule/Mass	0.880	Pulmonary fibrosis	0.910
Consolidation	0.916	Other lesion	0.910	No finding	0.978




Figure 1: Entraînement (30 epochs, seed 42). Gauche : loss d'entraînement et de validation (entropie croisée binaire multi-label). Droite : accuracy de validation (seuil 0.5), bruitée mais stable autour de 0.70 après la convergence.

3.2 Hiérarchie couche × méthode

La table 2 synthétise les métriques des deux couches (moyenne $\pm$ écart-type, $n = 442$ findings issus de 500 images). À layer4, Grad-CAM++ domine : pointing game de 0.161 (IC 95 % 0.143–0.232) contre 0.109 pour Grad-CAM, IoU de 0.091 contre 0.059; les différences sont significatives au test de Wilcoxon apparié avec correction de FDR ($q < 0.002$). À layer3, Grad-CAM++ est en revanche le pire des trois méthodes (pointing game 0.007), ce qui montre que son avantage dépend de la couche choisie.

Table 2: Métriques de localisation par couche et méthode (moyenne $\pm$ écart-type, $n = 442$ findings). Distance normalisée : plus bas est meilleur.

	layer3			layer4		
	Grad-CAM	Grad++	XGrad	Grad-CAM	Grad++	XGrad
Pointing game $\uparrow$	0.081 $\pm$ 0.274	0.007 $\pm$ 0.082	0.070 $\pm$ 0.256	0.109 $\pm$ 0.311	0.161$\pm$0.368	0.109 $\pm$ 0.311
Energy in box $\uparrow$	0.050 $\pm$ 0.072	0.033 $\pm$ 0.040	0.045 $\pm$ 0.060	0.052 $\pm$ 0.085	0.054$\pm$0.070	0.052 $\pm$ 0.085
IoU $\uparrow$	0.041 $\pm$ 0.073	0.029 $\pm$ 0.038	0.040 $\pm$ 0.077	0.059 $\pm$ 0.102	0.091$\pm$0.115	0.059 $\pm$ 0.102
Distance $\downarrow$	2.91 $\pm$ 3.50	3.68 $\pm$ 4.57	2.86 $\pm$ 3.70	2.74 $\pm$ 4.30	2.23$\pm$3.59	2.74 $\pm$ 4.30

XGradCAM et Grad-CAM coïncident exactement à layer4 (écart maximal $\leq 3 \times 10^{-6}$). Cette identité n'est pas un artefact d'implémentation : à layer4, la tête de classification est un global average pooling suivi d'une couche linéaire, ce qui rend le gradient du score **constant dans l'espace**; la pondération de XGradCAM, qui pondère les gradients par les activations, se réduit alors exactement à la moyenne spatiale des gradients utilisée par Grad-CAM. Les deux méthodes divergent à layer3 (pointing game 0.081 contre 0.070), où la queue du réseau est non linéaire.

La figure 2 restitue le même résultat sous forme graphique pour les quatre métriques : à chaque fois, layer4 domine layer3 pour Grad-CAM++ et XGradCAM, et Grad-CAM++ à layer4 forme le maximum sur les trois métriques à sens croissant (pointing game, energy in box, IoU) ainsi que sur la distance (sens décroissant). Seul Grad-CAM reste relativement stable entre les deux couches, cohérent avec le test apparié de la section suivante.




Figure 2: Moyennes des quatre métriques de localisation par méthode (axe des x) et par couche (couleur). Plus haut est meilleur, sauf pour la distance (plus bas est meilleur). Grad-CAM++ à layer4 domine sur toutes les métriques; Grad-CAM++ à layer3 s'effondre (pointing game 0.007), montrant que son avantage est conditionné à la couche.

La comparaison appariée layer4 contre layer3 (paires image $\times$ pathologie, 12 tests, correction de Benjamini–Hochberg) confirme la supériorité de layer4 pour Grad-CAM++ (meilleur sur les quatre métriques, $q \leq 9 \times 10^{-46}$) et, de façon plus nuancée, pour Grad-CAM : IoU ($q = 1,2 \times 10^{-6}$) et distance ($q = 1,6 \times 10^{-3}$) significatives, mais pointing game non significatif après correction ($q = 0,084$). Nous recommandons donc **layer4 + Grad-CAM++** comme configuration par défaut ; il s'agit de la meilleure des six configurations évaluées, sans prétention d'optimalité globale.

3.3 Analyse par pathologie




Figure 3: Pointing game par pathologie et configuration. Les pathologies étendues centrales (Cardiomegaly, ILD) sont les mieux localisées; les lésions focales (Pleural thickening, Calcification, Pneumothorax) ne sont jamais localisées.

La figure 3 et la table 3 décomposent le pointing game par pathologie (layer4 + Grad-CAM++). Une hiérarchie nette apparaît, corrélée à la taille et la position des lésions : cardiomegaly 0.474 ($n = 76$, IC 0.36–0.58), ILD 0.417 ($n = 12$, IC 0.17–0.67), consolidation 0.333 ($n = 12$). À l’opposé, pleural thickening ($n = 64$), calcification ($n = 10$) et pneumothorax ($n = 4$) ne sont jamais localisés; nodules/masses 0.087 ($n = 23$). Les effectifs faibles de certaines classes (atelectasis $n = 3$, pneumothorax $n = 4$) rendent leurs estimations très incertaines (IC larges), à l’inverse d’Aortic enlargement ($n = 99$) et Pleural thickening ($n = 64$). Ce gradient suggère que Grad-CAM capture les patterns diffus ou centraux mais échoue sur les lésions focales périphériques de petite taille.

Table 3: Pointing game par pathologie (layer4 + Grad-CAM++). IC 95 % par bootstrap dés images. n = nombre de findings.

Pathologie	n	PG	IC 95 %	Pathologie	n	PG	IC 95 %
Cardiomegaly	76	0.474	0.355–0.579	Other lesion	31	0.097	0.000–0.226
ILD	12	0.417	0.167–0.667	Nodule/Mass	23	0.087	0.000–0.217
Atelectasis	3	0.333	0.000–1.000	Infiltration	15	0.067	0.000–0.200
Consolidation	12	0.333	0.083–0.583	Aortic enlargement	99	0.040	0.010–0.081
Lung Opacity	27	0.222	0.074–0.371	Calcification	10	0.000	0.000–0.000
Pleural effusion	28	0.179	0.036–0.321	Pleural thickening	64	0.000	0.000–0.000
Pulmonary fibrosis	38	0.105	0.026–0.211	Pneumothorax	4	0.000	0.000–0.000

3.4 Contrôles et test de randomisation

Le tableau ci-dessous rapporte les contrôles globaux (score moyen (pointing game + energy in box) / 2, $n = 442$). Ce score combiné n’est pas une métrique conventionnelle : il couple l’atteinte de l’argmax par la box (binaire) à la proportion d’énergie dans la box (continue), pris à parts égales et à l’identique dans les quatre conditions, ce qui rend les comparaisons internes cohérentes tout en évitant qu’une seule composante domine ; les deux métriques séparées sont rapportées par ailleurs (table 2), et les réserves de lecture ci-dessous valent pour le score combiné seul. Le modèle entraîné (0.080 ± 0.183) est significativement supérieur au modèle à poids randomisés (0.023 , $p = 6.17\text{e-}09$), démontrant que la localisation exploite des features apprises. En revanche, la différence avec le modèle non entraîné (0.031 , $p = 0.36$) et avec des cartes aléatoires (0.036 , $p = 1.00$) n’atteint pas la significativité dans ce test. Ce résultat s’explique par la nature même du test de Mann-Whitney, qui compare les distributions entières (dominance stochastique) et non les moyennes : les scores réels sont extrêmement asymétriques (médiane 0.008, 21 % de zéros), leur moyenne étant portée par un petit nombre de localisations réussies (cardiomegaly), tandis que les cartes aléatoires produisent un plancher quasi constant. Le fait que le modèle entraîné ne surpasse pas non plus l’initialisation aléatoire ne signifie pas un apprentissage nul : un réseau convolutif non entraîné génère déjà des cartes lisses et centrées (prior architectural, images centrées), dont le plancher d’énergie dans la box est du même ordre ; seule la destruction des poids appris (randomisation) abaisse ce plancher significativement. La puissance de ces tests est par ailleurs limité par la proportion de zéros. Des tests appariés par finding, plus adaptés

à ces distributions zéro-inflées, n'ont pas pu être calculés faute de scores nuls individuels sauvegardés, et constituent une extension nécessaire (voir les limites, section 4).




Figure 4: Score de localisation du modèle entraîné vs trois contrôles, par pathologie (Grad-CAM, layer4, score combiné). La cardiomegaly est la seule classe où le modèle entraîné dépasse nettement tous les contrôles. Pour l'ILD, les poids randomisés dépassent le modèle entraîné, signe d'un artefact architectural pour cette configuration (voir la réserve de la section 3.4).

L'analyse par pathologie (figure 4) nuance fortement le tableau global. Pour la **cardiomegaly**, le modèle entraîné (0.262) surpasse massivement tous les contrôles (randomisé : 0.007, $p = 2.86e-21$), ce qui témoigne d'une vraie localisation apprise. Pour l'**ILD**, en revanche, le modèle à poids randomisés (0.204) dépasse le modèle entraîné (0.109, $p = 0.96$) : pour Grad-CAM et le score combiné utilisés ici, la localisation apparente de l'ILD est un **artefact architectural**, non le reflet de features appris. Réserve importante : le pointing game de 0.417 de la section 3.3 est mesuré avec Grad-CAM++, pour lequel les contrôles n'ont pas été recalculés ; l'extension de l'artefact à Grad-CAM++ est plausible (même architecture, même prior central) mais reste à démontrer : la conclusion sur l'ILD vaut pour la seule configuration contrôlée. Les 14 tests par condition sont corrigés par la méthode de Benjamini–Hochberg : après correction, seules la cardiomegaly (contre les trois contrôles, $q \leq 2,7 \times 10^{-8}$), l'aortic enlargement (contre les poids randomisés et les cartes aléatoires) et la pleural thickening (contre le modèle non entraîné et les poids randomisés) restent significatives ; seul l'effet cardiomegaly survit à l'ensemble des conditions. Ce résultat, rarement rapporté, souligne l'importance du test de randomisation des poids avant toute interprétation clinique des cartes CAM.

3.5 Exemples qualitatifs et classe No finding

La figure 5 confronte directement des succès et des échecs du pointing game (Grad-CAM++, layer4). Les quatre succès montrés sont des cardiomegalies : la box, large et centro-médiastinale, contient le maximum de la carte, qui concentre de toute façon son activation la plus forte sur cette région. Les quatre échecs sont des nodule/mass : la box est petite et située en périphérie pulmonaire, tandis que la carte reste centrée sur le médiastin et les hiles ; l'argmax tombe hors box, parfois à distance considérable. Cet écart illustre mécaniquement les analyses quantitatives des sections 3.3 et 4 : la carte suit un prior spatial central, qui coïncide avec les lésions étendues centrales et manque systématiquement les lésions focales périphériques. La figure 6 montre le même pattern sur d'autres pathologies : activation centro-médiastinale diffuse quelle que soit la classe, coïncidence avec la box pour la cardiomegaly, miss pour les lésions périphériques (calcification). Pour *No finding*, sans bounding box, les cartes sont fortement diffuses (entropie spatiale ≈ 14.6 – 15.6 bits, proche du maximum), avec une concentration dans le top 1% des pixels de seulement 3.6–4.7%. Cette diffusivité est cohérente avec l'absence de lésion focale, validant indirectement le comportement du modèle sur cette classe.

4 Discussion

Cette étude fournit une validation quantitative rigoureuse de Grad-CAM en imagerie thoracique, avec trois enseignements. Premièrement, la fidélité spatiale dépend fortement de la pathologie : la localisation suit un gradient corrélé à la taille et la centralité de la lésion, la plus élevée pour la cardiomegaly (pointing game 0.474,




Figure 5: Succès et échecs du pointing game (Grad-CAM++, layer4). Colonnes : image originale, carte CAM, carte avec box de vérité terrain (vert). Lignes 1–4 : cardiomegalies, succès (PG = 1), la box large et centrale contient l'argmax. Lignes 5–8 : nodules/masses, échecs (PG = 0), la carte reste centrale pendant que la box siège en périphérie.




Figure 6: Exemples Grad-CAM++ (layer4) sur d'autres pathologies. Colonnes : image originale, carte CAM, carte avec box de vérité terrain (vert). L'activation centro-médiastinale diffuse est systématique et ne coïncide avec la box que pour les pathologies centrales étendues.

IC 0.36–0.58, donc encore imparfaite : l'argmax sort de la box dans plus de la moitié des cas) mais nulle pour les nodules et pneumothorax. Ce gradient rejoint les observations de Saporta et al. [2], pour qui les échecs de Grad-CAM concernent préférentiellement les lésions petites et de forme complexe. Les cartes CAM peuvent donc servir d'indice pour les pathologies étendues, mais ne doivent jamais être utilisées seules pour exclure ou localiser une micro-lésion. Deuxièmement, le test de randomisation des poids s'avère indispensable : sans lui, la localisation de l'ILD aurait été interprétée à tort comme un succès ; le contrôle montre qu'au moins pour Grad-CAM, elle relève d'un biais architectural, le prior centro-médiastinal, plutôt que de features appris. L'extension de ce contrôle à Grad-CAM++, qui porte le pointing game à 0.417, reste à faire et conditionne la portée finale de ce constat (voir les limites). Ce résultat invite à la prudence dans une littérature où ce contrôle est rarement présenté, y compris dans les travaux récents qui se limitent à une validation qualitative des cartes Grad-CAM par un clinicien [7]. Troisièmement, la configuration recommandée est layer4 + Grad-CAM++, la meilleure des six évaluées sur toutes les métriques à layer4, la couche la plus profonde portant la sémantique la plus riche.

Limites

Le modèle est entraîné from scratch, sans pré-entraînement ImageNet, ce qui peut sous-estimer la qualité de localisation atteignable. Les bounding boxes agrègent plusieurs radiologues sans modélisation explicite du désaccord inter-annotateurs ; retenir le meilleur score parmi les boxes revient à biaiser les mesures vers le haut. Les métriques supposent une box rectangulaire, approximation grossière pour des lésions de forme irrégulière ; l'IoU binarisée à 0.5 reste arbitraire pour des cartes non calibrées, et la distance au centre pénalise les grandes boîtes même si le maximum en est proche. Les comparaisons globales de contrôles reposent sur un test non apparié (Mann-Whitney) ; les tests par pathologie sont corrigés par Benjamini-Hochberg, mais les scores nuls individuels n'ont pas été sauvegardés, ce qui empêche de calculer les tests appariés (Wilcoxon) et le bootstrap par image sur les contrôles, à produire néanmoins. Les contrôles ont été calculés avec Grad-CAM et le score combiné, alors que la configuration recommandée est Grad-CAM++ : la conclusion d'artefact architectural pour l'ILD n'est donc démontrée que pour Grad-CAM, et son extension à Grad-CAM++ reste à vérifier. Les performances de classification sont limitées à l'AUC par classe : l'average precision, le F1 à seuil et la calibration, plus adaptés au déséquilibre multi-label, ne sont pas encore mesurés. Certains effectifs par pathologie sont très faibles (pneumothorax $n = 4$, atelectasis $n = 3$), leurs IC étant de ce fait très larges. Un seul split (seed=42) et un seul entraînement ont été utilisés : la variabilité entre seeds n'est pas estimée. Trois à cinq réentraînements permettraient de quantifier cette variance et de vérifier que les écarts rapportés (layer4 contre layer3, cardiomegaly contre les autres classes) la dépassent ; à défaut, faute de ressources de calcul, ces écarts doivent être lus comme des ordres de grandeur ponctuels, en particulier pour les classes à faible effectif (atelectasis $n = 3$, pneumothorax $n = 4$), dont la variance entre seeds serait à elle seule considérable. Enfin, l'évaluation est limitée à un seul dataset (VinDr-CXR) et une seule architecture (ResNet-50) ; une validation externe (CheXpert, NIH ChestX-ray14) serait nécessaire pour généraliser.

Les travaux futurs incluront l'utilisation de poids pré-entraînés, l'extension à des méthodes d'explicabilité plus récentes (Score-CAM [8], Layer-CAM [9]), et une évaluation clinique avec des radiologues mesurant l'impact réel de ces cartes sur la décision diagnostique.

5 Conclusion

Nous avons évalué quantitativement la fidélité spatiale de Grad-CAM contre des annotations radiologiques sur VinDr-CXR. Le classifieur discrimine bien (AUC macro 0.920), mais la localisation est relativement la plus élevée pour les lésions étendues centrales (cardiomegaly, pointing game 0.474) tout en restant imparfaite même pour cette classe, et quasi nulle pour les lésions focales. Pour l'ILD, les contrôles (Grad-CAM) mettent en évidence un artefact architectural ; l'étendre à Grad-CAM++, configuration la plus performante, reste à confirmer. Nous recommandons layer4 + Grad-CAM++ comme configuration par défaut, assortie d'un test de randomisation des poids systématique avant toute interprétation clinique. Ces résultats fournissent à la communauté des métriques reproductibles et des recommandations concrètes pour un usage responsable des cartes de saillance en imagerie médicale.

6 Code et données

Le code source du modèle, d'évaluation, les scripts d'analyse statistique (scripts/, src/) et les résultats bruts (outputs/) sont fournis avec ce rapport et publiés sur GitHub : <https://github.com/5uru/XLoc-CXR>. VinDr-CXR est un jeu de données public [3], utilisable sous sa licence d'origine.

Références

- [1] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2):336–359, 2019.

- [2] Adriel Saporta, Xiaotong Gui, Ashwin Agrawal, Anuj Pareek, Steven Q. H. Truong, Chanh D. T. Nguyen, Van-Doan Ngo, Jayne Seekins, Francis G. Blankenberg, Andrew Y. Ng, Matthew P. Lungren, and Pranav Rajpurkar. Benchmarking saliency methods for chest X-ray interpretation. *Nature Machine Intelligence*, 4(10):867–878, 2022. <https://www.nature.com/articles/s42256-022-00536-x.pdf>.
- [3] Ha Q. Nguyen, Khanh Lam, Linh T. Le, Hieu H. Pham, Dat Q. Tran, Dung B. Nguyen, Dung D. Le, Chi M. Pham, Hang T. T. Tong, Diep H. Dinh, Cuong D. Do, Luu T. Doan, Cuong N. Nguyen, Binh T. Nguyen, Que V. Nguyen, Au D. Hoang, Hien N. Phan, Anh T. Nguyen, Phuong H. Ho, Dat T. Ngo, Nghia T. Nguyen, Nhan T. Nguyen, Minh Dao, and Van Vu. VinDr-CXR: An open dataset of chest X-rays with radiologist’s annotations, 2020. <https://github.com/vinbigdata-medical/vindr-cxr>.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [5] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019. <https://arxiv.org/abs/1711.05101>.
- [6] Aditya Chattopadhyay, Anirban Sarkar, Prantik Howlader, and Vineeth N. Balasubramanian. Grad-CAM++: Generalized gradient-based visual explanations for deep convolutional networks. In *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 839–847, 2018.
- [7] Rakesh S. Raj, Pavan M. P. Kumar, K. N. Manjunath, B. E. Rangaswamy, H. S. Nagendraswamy, C. B. Lavanya, Kailash Hambarde, and M. Varsha. Hybrid MobileNetV2–vision transformer approach for multi-label classification of chest X-rays. *Scientific Reports*, 2026. <https://www.nature.com/articles/s41598-026-68788-w>.
- [8] Haofan Wang, Zifan Wang, Mengnan Du, Fan Yang, Zijian Zhang, Sirui Ding, Piotr Mardziel, and Xia Hu. Score-CAM: Score-weighted visual explanations for convolutional neural networks, 2020. Accepted to CVPR 2020 Workshop on Fair, Data Efficient and Trusted Computer Vision.
- [9] Peng-Tao Jiang, Chang-Bin Zhang, Qibin Hou, Ming-Ming Cheng, and Yunchao Wei. LayerCAM: Exploring hierarchical class activation maps for localization. *IEEE Transactions on Image Processing*, 30:5875–5888, 2021.